CIENCIA DE DATOS E INTELIGENCIA ARTIFICIAL 3ºCURSO

UNIVERSIDAD POLITÉCNICA DE MADRID

APRENDIZAJE AUTOMÁTICO

PRACTICA DE CLUSTERING

22/10/2025

DIEGO JOSÉ GARCÍA CALLEJAS

dj.garcia.callejas@alumnos.upm.es

HÉCTOR FERNÁNDEZ CANO

hector.fernandez@alumnos.upm.es

1.Introducción

En esta entrega analizaremos el conjunto de datos 'data-odd.csv' con el objetivo de identificar agrupaciones naturales de individuos y comparar varios métodos de clustering(Kmeans, Jerárquico,...).Para este proceso, como comentaremos en los diferentes apartados , llevaremos a cabo distintas técnicas, tanto de escalado como de clustering .Finalizaremos con un análisis más exhaustivo de la mejor técnica obtenida para poder sacar relaciones entre las variables que conforman los datos. Una vez finalizado, seremos capaces de observar patrones en los datos proporcionados

2.Métodos

Comenzamos el preprocesamiento del csv cargando los datos en memoria con ayuda de la librería pandas y analizando las columnas que forman dicho fichero, ya que a pesar de que se nos ofreció una breve descripción queríamos comprobar si podíamos extraer alguna conclusión a partir de ellas. Tras esto, pudimos diferenciar las columnas cuantitativas('Age','EducationNum','CapitalGain', 'HoursPerWeek') de las cualitativas ('Education', 'MaritalStatus', 'Relationship', 'Gender'), que nos permitiría separarlas para poder aplicar las respectivas transformaciones.

El análisis comenzó con un estudio individual de las variables, para poder obtener información sobre sus valores y el número de frecuencias de cada uno de estos. Para realizar esto, necesitamos la ayuda de matplotlib para la realización de las distintas gráficas (histogramas, boxplot y diagramas de barras). Dicho análisis nos llevó a las siguientes conclusiones:

- **Age**: informa sobre la edad de los sujetos, con un rango entre 17 y 90 años, donde la mayor parte se encuentra desde los 17 hasta los 45, es decir, son datos de personas relativamente jóvenes.
- **Education** y **EducationNum**: representan la misma información, el nivel educativo de los individuos. La primera es una variable categórica mientras que la segunda es su versión cuantitativa, obtenida tras asignar un valor entero a cada categoría de *Education*. Por tanto, ambas son redundantes, ya que una es el resultado de haber aplicado una transformación a la otra.
- **MaritalStatus**: variable cualitativa que proporciona información sobre el estado civil de los sujetos. Sus valores pueden ser:
    - **Married-civ-spouse**: casado/a con pareja civil.
    - **Never-married**: nunca casado/a.
    - **Divorced**: divorciado/a.
    - **Separated**: separado/a (aún casado).
    - **Widowed**: viudo/a.
    - **Married-spouse-absent**: casado/a pero la pareja no vive en el hogar.
    - **Married-AF-spouse**: casado/a con una pareja en las Fuerzas Armadas

  Siendo las categorías casado/a y nunca casado/a las más abundantes, lo cual se verá reflejado en futuras variables.

- **Relationship**: variable cualitativa que representa el rol del sujeto en su ámbito familiar. Los valores que puede tomar son:

- **Not-in-family**: no pertenece a una familia
- **Husband**: esposo.
- **Unmarried**: persona no casada.
- **Own-child**: hijo/a propio/a.
- **Wife**: esposa.
- **Other-relative**: otro familiar (tío, primo, etc.).

Los valores más abundantes son Not-in-family y Husband. El primero está relacionado con la categoría Never-married de la variable MaritalStatus, lo que indica que una gran parte de los individuos no está casada ni forma parte de un núcleo familiar. En cambio, la categoría Husband se asocia con Married-civ-spouse, lo que refleja que hay un número considerable de hombres casados en la muestra.

- **Gender**: proporciona el género de los sujetos (hombre o mujer). La elevada presencia de la categoría Husband en la variable Relationship ya adelantaba lo que se observa en la variable Gender, donde el número de hombres supera al de mujeres.
- **CapitalGain**: representa el beneficio ganado por los sujetos. Tras el análisis de la variable, se pudo observar la enorme cantidad de ceros en ella y unos pocos valores muy alejados de estos, posible indicio de que solo unas pocas personas han conseguido obtener beneficios de sus inversiones o que muy pocos han invertido.
- **HoursPerweek**: representa el número de horas que trabaja cada persona a la semana. Toma valores desde 1 a 99 horas , siendo 40 el número medio de horas.

Antes de empezar a aplicar el escalado de las variables, nos aseguramos que no existan nulos y no hubiese repetidos. En el dataset no existen nulos, sin embargo, hay una gran cantidad de datos repetidos, por lo que tenemos que proceder a eliminarlos, con la ayuda de la librería pandas (drop_duplicates())

Tras comprobar todo esto, decidimos eliminar la columna redundante de 'Education', que como ya mencionamos equivale a la columna 'EducationNum'

Para comenzar con el escalado, lo primero que hemos realizado ha sido la concatenación de los dataframes con las variables cuantitativas con las variables categóricas transformadas a cuantitativas, mediante OneHotEncoder, para poder escalar todas las variables al mismo tiempo.

Nuestra idea al realizar los escalados es comprobar aquellos escaladores que nos den un mejor clustering,basándonos en los gráficos de PCA que realizaremos en cada uno de ellos. Para realizarlo hemos optado por distintas estrategias de escalado que se detallan a continuación:

Comenzamos este proceso eligiendo el escalado de estandarización como primer candidato, por lo que aplicamos el método 'StandardScaler()' al conjunto de datos. Tras realizarlo, con la función 'describe()' visualizamos la estandarización para ver si estaban todas dentro de la misma escala, donde hemos podido ver que CapitalGain tiene una escala mayor, lo que puede hacer que esa variable tenga mayor peso a la hora de hacer el clustering.

En segundo lugar, hemos procedido de la misma manera con el escalado de MinMaxScaler con ayuda de la función 'MinMaxScaler()'. De igual manera hemos usado la función 'describe()' para

comprobar que ninguna variable no se hubiese escalado, pero en este caso, por la naturaleza del escalado, todas las variables están en el intervalo unidad. Por este motivo, estos datos no suponen el problema de que una variable tenga un mayor peso que otra.

En tercer lugar aplicamos MaxAbsScaler, de la misma manera que en los casos anteriores, mediante la función 'MaxAbsScaler()', y tras ello con la función 'describe()' comprobamos el escalado para ver si hubiese alguna variable fuera de rango, pero por su expresión, todos los valores van a ser menores o iguales que 1. Además, en este caso como todos los datos son positivos, todos serán mayores o iguales que 0, por lo que esto nos da una posible intuición de que el escalado se va a comportar de igual manera que el MinMaxScaler.

En cuarto lugar realizamos el escalado con 'RobustScaler()', para resolver nuestras dudas sobre el resultado de escalar con este método, ya que sabríamos que probablemente no funcionase correctamente puesto que la variable CapitalGain dispone de un rango intercuartílico de 0, factor fundamental en la fórmula del escalado. Una vez aplicado, nuestras sospechas se hacen realidad debido a que el resto de variables se han escalado correctamente, excepto esta variable que se ha mantenido igual, y por ello su escala. Por estos motivos tan evidentes hemos decidido no usar este tipo de escalado para realizar el clustering.

En quinto lugar realizamos una normalización con la función 'Normalize()' . Tras aplicar 'describe()' observamos que todas las variables se encuentran también en el intervalo unidad. Por eso también podemos intuir que en el clustering se va a comportar idénticamente o casi idénticamente al clustering realizado con los datos escalados con MinMaxScaler, aunque lo comprobaremos más adelante.

Por último lugar, al aplicar en todos los tipos de escalado la función describe() ,hemos ido observando que en todos la desviación típica es muy distinta. En un primer momento nos resultó razonable y correcto aplicar 'Normalize()' con la norma l1 a las variables transformadas con OneHotEncoder (en adelante las denominaremos OneHot), ya que el resultado de este aplicado a todas las variables conseguía lo que queríamos, que la varianza de todas las numéricas sean parecidas y que las OneHot en su conjunto tengan una varianza similar a las numéricas. Sin embargo, vimos que la desviación típica de cada una de las OneHot era extremadamente baja por lo que en su conjunto no era similar a la desviación típica de las numéricas. Se nos ocurrió otra manera, que era utilizar StandardScaler y al resultado dividir el resultado de cada tipo de variable categórica entre el número de OneHot que se han creado de dicha categoría. Se pudo observar que este resultado nos aproximaba más la varianza de las OneHot en su conjunto. Finalmente, el escalado de las OneHot se ha realizado de dicha manera. Por otro lado, para las variables cuantitativas se ha decidido realizar un escalado con RobustScaler, menos a CapitalGain, la cual ha sido escalda con MaxAbsScaler, consiguiendo una desviación bastante pequeña para esta variable , ya que hemos preferido no darle mucha importancia a esta variable por los escasos y diferentes valores de esta .

Con el objetivo de conocer si existe alguna posible agrupación que divida a los individuos de la muestra en grupos con características similares, y así obtener un mayor conocimiento sobre los aspectos sociales y económicos y las variables que influyen en ellos. Los métodos de clustering utilizados son:

- KMeans, con 3 clusters
- KMeans, con diferentes clusters para averiguar el número óptimo.

- Jerarquico, con diferentes tipos de enlaces (*single, complete, ward, average*)
- DBScan
- Mixturas de Gaussianas, con diferentes tipos de covarianzas (*full, spherical, tied, diag*) y de componentes

3.Resultados

El proceso de clustering comienza con el método de KMeans con parámetro k=3, el cual ha sido aplicado a los diferentes datos escalados, con el motivo de observar el comportamiento de las métricas de escalado. Como complemento a estas agrupaciones nos ayudamos de funciones que nos permitieran observarlas y compararlas, como por ejemplo , el coeficiente de silhouette, el cual nos informa de que tan bien están separados y definidos los clusters. No pondremos especial atención a los resultados porque como ha sido mencionado, es un acercamiento a los diferentes escalados.

En cuanto al análisis visual del clustering realizado con cada tipo de escalado, estos se han realizado mediante PCA. No obstante, por motivos de extensión, se ha decidido no adjuntar las imágenes correspondientes, presentando únicamente el análisis de los resultados obtenidos.

- MinMaxScaler: en primer lugar aplicamos este método a los datos escalados con MinMaxScaler, inicializado 40 veces para quedarnos con el mejor resultado. Tras realizarlo, agregamos una columna ('Cluster') con valores 0,1 y 2, al dataframe de los datos para poder hacer un breve análisis del agrupamiento. Mediante la función 'value_counts()' podemos saber cuántas instancias hay en cada cluster y en este caso tienen un tamaño parecido , indicador de que el resultado va a ser más o menos bueno. Siguiendo con el análisis, utilizamos el coeficiente de silhouette, obteniendo 0.38 lo que es un buen valor, que nos indica que los clusters pueden estar bien separados, aunque puede que haya algún borde que se solape, ya que es alto, pero no muy cercano a 1, que sería cuando el resultado es perfecto. La representación PCA obtenida tras el clustering con este tipo de escalado muestra varias nubes de puntos claramente separadas. Al haberse fijado k=3, el algoritmo ha asignado distintas nubes a un mismo clúster, lo que provoca que grupos alejados aparezcan con el mismo color. Este comportamiento indica que el número de clústeres elegido no refleja adecuadamente la estructura real de los datos, o bien que la proyección mediante PCA no capta completamente la separación existente en el espacio original.

- StandarScaler: en segundo lugar, lo aplicamos a los datos escalados mediante StandardScaler, siguiendo el mismo procedimiento anterior. Tras realizarlo, añadimos como antes la columna "Cluster" al dataframe y utilizamos la función value_counts() para analizar la distribución de instancias en cada grupo. En este caso, observamos un resultado bastante anómalo, ya que los dos primeros clusters reúnen aproximadamente el 99% de los datos, lo cual indica que no se ha llevado a cabo una separación adecuada. Esta sospecha se confirma al calcular el coeficiente de silhouette, cuyo valor fue 0.22, bastante próximo a 0, lo que sugiere que los clusters no están correctamente definidos ni bien separados. Es probable que este resultado se deba a la variable CapitalGain, que como se observó anteriormente no fue escalada de manera correcta con esta técnica. Por último, calculamos el índice de Rand para comparar la similitud entre los clusterings obtenidos con MinMaxScaler y con StandardScaler, obteniendo un valor de 0.6, lo que indica una cierta coincidencia entre ambas agrupaciones. En este segundo análisis, PCA muestra una nube de puntos más compacta, lo que permite una segmentación más coherente de los datos. Se observa una separación no muy clara entre dos de los clústeres,

mientras que el tercero permanece bien diferenciado y no se solapa con los anteriores. Esta distribución facilita la interpretación visual y sugiere que el modelo ha captado mejor la estructura subyacente. Por ello, el resultado es más representativo que en el caso previo, donde los grupos aparecían más dispersos.

- MaxAbsScaler: en tercer lugar , aplicamos el modelo a los datos escalados con MaxAbsScaler. del mismo modo que en los dos casos anteriores. Añadimos la columna "Cluster" al dataframe ,una vez hecho obtenemos el número de instancias con la ayuda de nuevo de 'value_counts()', observamos que los clusters presentan una distribución de elementos prácticamente idéntica a la obtenida con MinMaxScaler anteriormente. Dicho resultado era esperable, ya que este método solo generaba valores positivos entre [0,1], por lo que las distancias son muy similares a las distancias del método de MinMaxscaler. El coeficiente de silhouette obtenido fue de 0.38, prácticamente idéntico al del MinMaxScaler, representando lo mismo que en el método mencionado. Al calcular el índice de Rand entre el clustering obtenido con MaxAbsScaler y el de MinMaxScaler, el resultado fue 1, lo que confirma que los clusters son idénticos, Del mismo, la comparación con StandardScaler devuelve el mismo valor que con MinMaxScaler. El resultado obtenido es prácticamente idéntico al obtenido con MinMaxScaler, lo que se refleja en una representación PCA muy similar. La única diferencia es que un punto ha cambiado de asignación de clúster, pasando a pertenecer a un grupo distinto. Por este motivo, el análisis es análogo al realizado para MinMaxScaler, manteniendo la misma interpretación.

- NormalizeScaler: en cuarto lugar, aplicamos el modelo a los datos escalados mediante Normalizer, repitiendo el mismo proceso que en los casos anteriores. Tras añadir la columna "Cluster", observamos la distribución de instancias con value_counts(). Sorprendentemente, la separación coincide con la del MinMaxScaler, salvo por una diferencia de una instancia entre los clusters 2 y 3. El coeficiente de silhouette obtenido fue de 0.55, mejor que con MinMaxScaler, lo que indica que puede existir una muy buena separación entre los clusters. No obstante, un valor alto de silhouette no garantiza necesariamente que el clustering sea el más adecuado, puesto que puede que su interpretación no tenga sentido. En este caso, la representación PCA presenta una nube de puntos con forma de 'C', en la que la parte superior corresponde a un clúster, la inferior a otro y, además, aparece una pequeña nube de puntos a la derecha que constituye un tercer clúster. Este patrón, poco habitual, puede deberse a haber escalado con Normalizer() ya que se aplica por instancia, haciendo que la norma de cada observación sea igual a 1. Esto puede alterar de manera significativa las relaciones de distancia originales entre puntos, modificando la estructura geométrica de los datos y generando agrupaciones inesperadas..

- No escalado: por último, aplicamos el modelo a los datos sin escalar, lo que nos permitirá observar la diferencia entre escalar y no hacerlo. Tras llevar a cabo el mismo procedimiento, observamos que el primer cluster obtiene el 93% de los elementos, lo que puede significar que al igual que ocurría en el escalado de StandardScaler, la columna CapitalGain tiene mayor peso. Observamos que su escala es mucho mayor (del orden de 10^5), mientras que el resto de variables se encuentran alrededor de 10^1 o 10^2. Además, el 90 % de los valores de CapitalGain son 0, lo que provoca que todos los elementos con esos valores se agrupen en un único cluster, generando una partición muy desequilibrada. Tras calcular el índice de Rand entre este clustering sin escalado y los obtenidos con datos escalados, se obtiene un valor del orden de 10^{-3}, prácticamente 0, lo que indica que los resultados son extremadamente distintos entre

ellos. En este caso, al trabajar con los datos sin escalar, la variable CapitalGain adquiere un peso muy elevado en la representación PCA. Esto provoca que los datos se distribuyen principalmente a lo largo del eje asociado a esta variable, aplanando el resto de dimensiones. Como resultado, se observa una gran concentración de puntos en la zona izquierda de la proyección correspondiente a valores bajos de CapitalGain, seguida de una franja intermedia para valores medios y, finalmente, una zona más alejada para valores altos. El PCA representa correctamente esta separación, pero la forma alargada y vertical de los clústeres indica que existe un solapamiento considerable entre observaciones, dificultando una segmentación nítida entre grupos

Tras analizar el funcionamiento del modelo para cada escalado, decidimos aplicar el método con un escalado personalida como se comentó en el apartado 2 (Variables OneHot → StandardScaler/número_categorias, Variables cuantitativas → RobustScaler, CapitalGain → MaxAbsScaler), el cual será el utilizado en los demás métodos. Tras llevar a cabo el mismo procedimiento, se observa que tanto el primer y segundo contienen la mayoría de los elementos, pero no existe un desequilibrio con respecto al tercero. El coeficiente de silhoutte obtenido es 19.6, lo cual no es muy bueno debido a que se traduce en la inexistencia de una clara separación de los datos. Para comprobar si este clustering tiene sentido, hemos realizado como en los casos anteriores un gráfico de las 2 componentes principales, que se muestra a continuación.

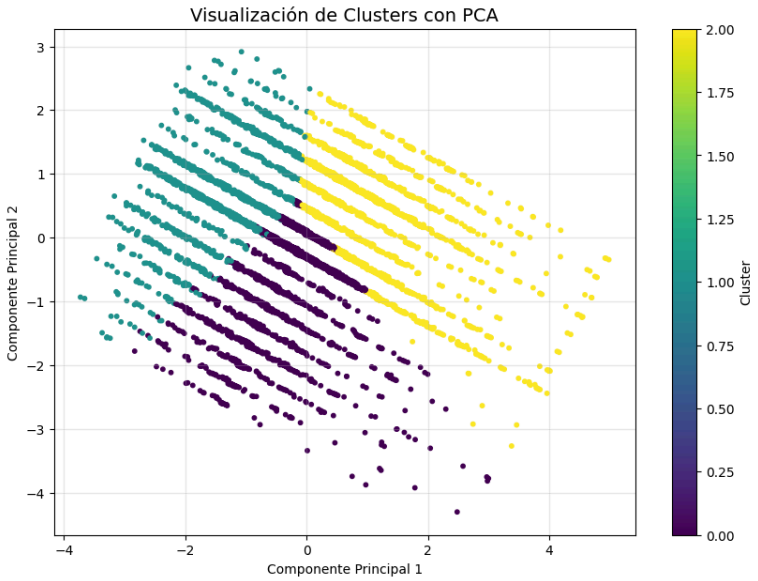

En este gráfico, se muestra que los clusters no están claramente separados,presentando cercanía entre estos. Aún asi podemos observar cierta agrupación sin una excesiva superposición de los puntos, donde cluster amarillo recoge la mayor parte en parte de arriiba a la derecha, el cluster azul verdoso en el lazo izquierdo con una menor cantidad de puntos y finalmente el cluster morado abajo en el centro, con un tamaño similar al cluster amarillo.

No está claro si el clustering es capaz de encontrar grupos exactos en los datos, debido a la cercanía de estos, pero si parece que existe una estructura oculta, que se puede observar claramente. Sin embargo, como comentaremos más adelante, este cluster no será el elegido, por lo que vemos innecesario su análisis.

Una vez terminado el análisis del modelo KMeans con k=3, es necesario analizar dicho modelo según la variación del número de cluster elegidos. Se consideró el rango de análisis desde k=2 hasta k=15, lo que nos permitiría obtener el número óptimo de cluster evitando la complejidad, debido a que a medida que crece el número de cluster lo hace su complejidad.

Hicimos uso tanto de la técnica del codo como del coeficiente silhoutte para obtener dicho valor. Por un lado, a medida que crece el número de cluster se reduce la inertia, es decir, van siendo más compactos los cluster. Por otro lado, graficando cada silhoutte de las diferentes agrupaciones pudimos elegir con más certeza el número de cluster ideal. Finalmente, tras llevar a cabo dicho análisis concluimos que k=4 es el valor óptimo, puesto que su inertia es baja sin diferir mucho con los valores más grandes y con un valor de silhouette de 0.20, siendo el mejor valor junto con k=5, pero como mencionamos antes, nos decantamos por aquellos valores que nos permiten obtener un modelo más simple y fácil de analizar.

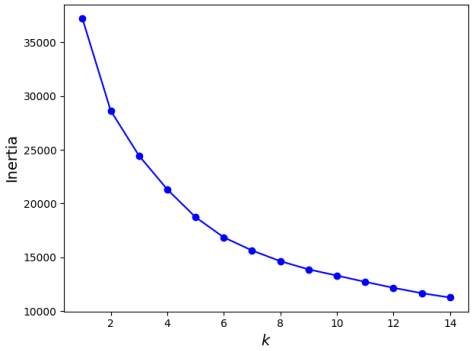

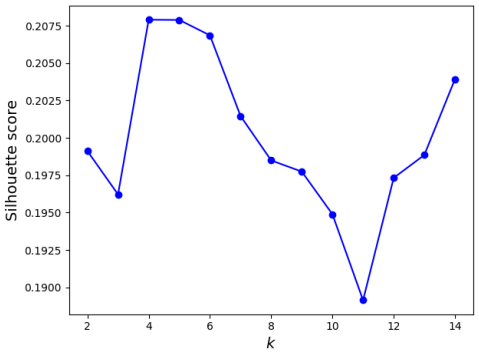

No comentaremos el clustering con KMeans con k=4, ya que más adelante lo haremos puesto que creemos que es la agrupación óptima.

Tras llevar a cabo este proceso, se llevó a cabo el análisis de los cluster jerárquicos, probando los diferentes tipos de 'linkage' para poder decidir el ótimo de estos. Para decidir cual de todos nos interesa más, hemos utilizado la función 'plot_dendograms()' proporcionada por el profesor que nos permite visualizar los dendrogramas y de esta manera, ofrecernos un mayor nivel de entendimiento de estos. Por último, mencionar que del mismo modo que ocurrió con KMeans, se ha realizado un breve análisis del coeficiente de silhoutte (solo el valor) de cada 'linkage' según los diferentes números de cluster que hemos considerado oportunos(rango [2,9]). Los 'linkages' analizados han sido:

- 'Complete': en el dendograma obtenido mediante el cluster jerárquico con el método 'complete' se puede observar que los grupos se van fusionando entre ellos hasta llegar a una altura de entre 8 y 9. Este método genera cluster más compactos y homogéneos, que visualmente muestra una estructura jerárquica y una distribución relativamente equilibrada, lo que puede sugerir que los datos pueden agruparse de manera adecuada con este método. Por otro lado, el mejor coeficiente de silhouette es 0.184 para 3 grupos, decreciendo los valores para grupos más grandes.

- Average: en el dendograma obtenido mediante el cluster jerárquico con el método 'average' se puede observar en este caso que los grupos se fusionan hasta una altura de aproximadamente 3.5, por lo que la mayoría de las fusiones ocurren en alturas bajas (individuos cercanos). En comparación con el dendrograma generado mediante el linkage

'complete' se han generado grupos visiblemente menos compactos . Centrándonos en el coeficiente de silhoutte, obtenemos valores mayores, siendo los más altos 0.527 (2 grupos) y 0.401 (3 grupos), por lo que aunque visualmente sea más dudoso, los cluster están bien compactos y separados unos de otros.

- 'Single': en el dendrograma obtenido mediante el cluster jerárquico con el método 'single' se puede observar en este caso que los grupos formados por la mayor parte de los datos se fusionan hasta una altura de aproximadamente 1.4, es decir, los individuos están muy cercanos. En comparación con los dendrograma generado mediante los linkages 'complete' y 'average' se generan grupos pocos compactos, que seguramente den lugar a un único cluster con forma irregular,por lo que creemos que no es un método adecuado de separación. Centrándonos en el coeficiente de silhoutte, obtenemos valores mayores, siendo los más altos 0.527 (2 grupos) y 0.510 (3 grupos), sin embargo, aunque tengan valores altos, los cluster generados seguramente serían muy irregulares y poco compactos.

- 'Ward': en último lugar, el dendrograma obtenido mediante el cluster jerárquico con el método 'ward' se puede observar que los grupos se fusionan en una altura 100. En comparación con los demás dendrograma, se puede observar una estructura jerárquica más clara y equilibrada, pues este método ofrece clusters compactos, separados entre sí, sin la influencia de datos atípicos. Este comportamiento se observa en los coeficientes de silhoutte donde el valor más alto ha sido 0.23 (3 grupos), ya que aunque no exista una diferencia con los demás coeficientes, sabemos que este método es el más adecuado para realizar agrupaciones, siendo el más utilizado en el día a día.

Tras observar el rendimiento de los diferentes tipos de enlaces y su comportamiento, se ha optado por el método de 'Ward', debido a que como se mencionó anteriormente, es el método más común para la obtención de grupos compactos y separados entre sí, lo cual coincide con la finalidad del proyecto.

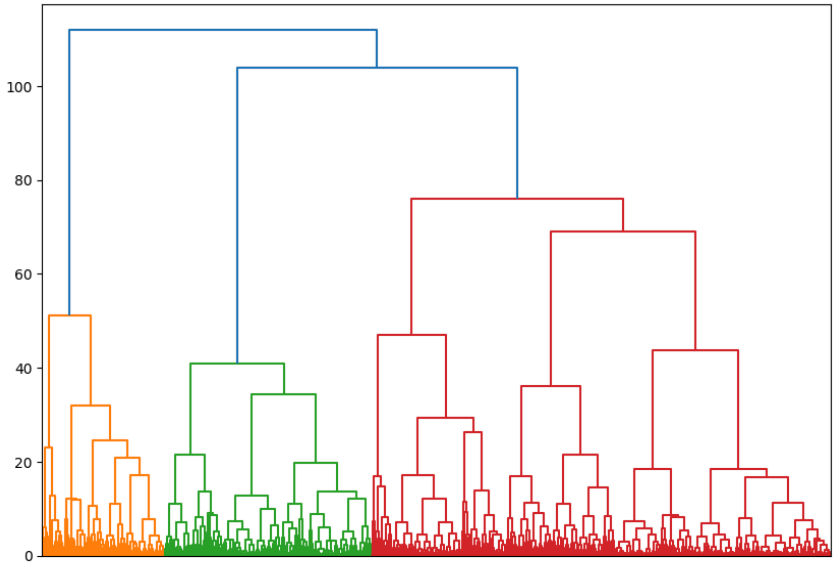

Se adjunta la imagen del dendrograma generado con el método ward

El método de enlace Ward proporciona como hemos mencionado varias veces clusters compactos y homogéneos gracias a minimizar las varianzas dentro de los grupos, lo que además lo convierte en un

método robusto a datos atípicos. Del mismo modo, logra evitar estructuras irregulares y poco separadas. Tras observar detenidamente el dendrograma creemos un cluster razonable daría lugar a 3 grupos , debido a que es el que tiene el coeficiente más alto de silhouette. Para realizar dicha separación deberíamos cortar a una altura cercana a 100, proporcionando unos cluster equilibrados y con buena separación entre ellos. Estos 3 grupos, seguramente estén agrupados en torno a variables importantes como pueden llegar a ser el nivel educativo, la edad o las horas trabajadas, puesto que son las variables que pueden marcar una mayor diferencia entre los grupos, dando lugar a grupos compactos y con una separación clara respecto a los otros

Por otro lado hemos aplicado DBScan, al igual que en los casos anteriores, se lo hemos aplicado al conjunto de datos escalados con un conjunto de técnicas diferentes. Como sabemos, este tipo de clustering tiene sentido cuando le podemos dar un sentido a los parámetros epsilon y min_samples, algo que en nuestro trabajo no era fácil. A pesar de ello hemos buscado realizarlo, para conocer si en este caso daría como resultado una buena agrupación. Para los valores hemos ido probando y finalmente hemos obtenido un coeficiente de silhouette de -0.029, con los siguiente parametros: ε= 0.9 y min_samples= 20, ya que viendo PCA's de otros modelos podemos ver que hay muchos puntos juntos por lo que hemos intentado poner un ε pequeño y un numero minimo de muestras elevado, para intentar conseguir que haya varios clusters con una densidad alta de puntos. A pesar de ello el siguiente gráfico muestra el PCA correspondiente que como podemos ver no se aprecia apenas separación como nos indicaba el coeficiente de silhouette por lo que hemos decidido descartar este modelo por la dificultad de obtener unos parámetros con sentido y por el mal resultado que nos ha ofrecido.

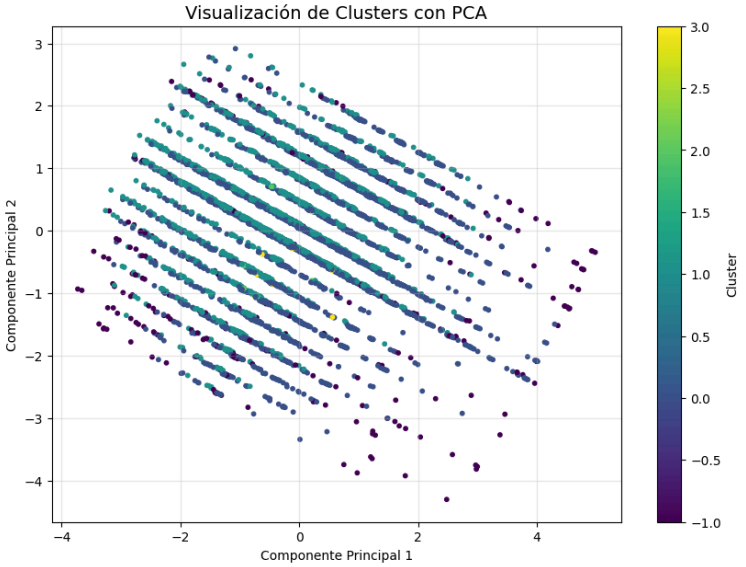

Vemos que se ven clusters diferenciados, pero aun así no nos ofrece la separación que nos ofrece KMeans con 6 clusters, ya que podemos ver que el cluster de color azul turquesa está donde el morado por lo que no hay una separación clara en esa zona, es por ello y por la dificultad de conocer sus parámetros para alcanzar el óptimo que rechazamos este modelo a pesar, de aparentemente también de presentarnos un gran resultado.

Por último hemos realizado clustering con Mixturas de Gaussianas, para este tipo de clustering, hemos utilizado una función hecha en clase en la cual se prueban los mejores modelos, para distinto número de componentes (clusters) y distintos tipos de covarianza. Utilizamos el BIC score para decidir cuál de

los métodos es el mejor (Cuanto menor sea BIC score mejor será nuestro método). El mejor clustering que obtenemos es con 4 componentes con una covarianza de tipo *full* lo cual nos da un BIC score de -180374.908. Una vez conocido este mejor método, lo que hacemos es que con el mejor modelo que hemos obtenido, calculamos el coeficiente de silhouette, el cuál nos da -0.017 algo bastante cercano a 0, y negativo, por lo que parece que hay puntos asignados a componentes que están más cerca de puntos de otra componente de a la que se le ha asignado al realizar el clustering. Como podemos ver en el siguiente grafico, la mayoría de los puntos están asociados a una única componente (amarillo), por lo que parece que hay puntos de esa componente que está más cercano a otras componentes. Esto parece que ocurre con puntos de la componente azul. Hemos decidido rechazar este modelo, por el resultado que nos ha ofrecido este clustering, ya que como podemos ver en el gráfico la separación apenas es notable.

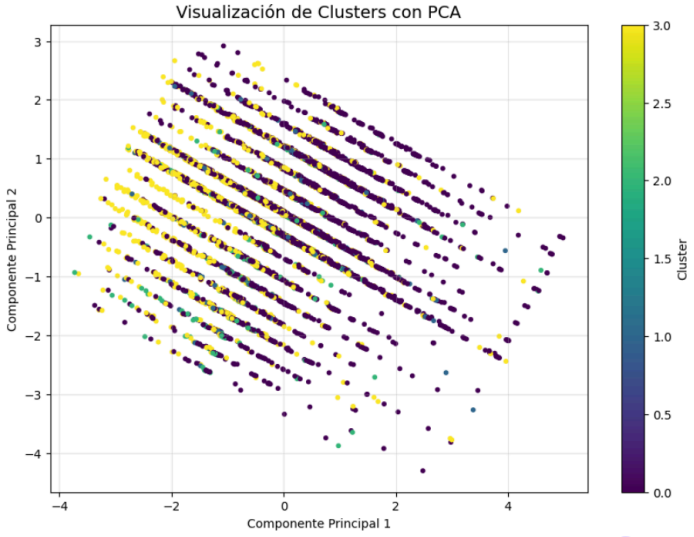

Finalmente, tras haber realizado todos los procedimientos necesarios para clasificar tanto las técnicas de clustering como de preprocesado, es el momento de elegir la técnica que más se ajuste a los datos y de este modo, intentar obtener relaciones que me permitan describir tanto las similitudes y diferencias de los grupos generados y generar patrones.

Es por ello que se ha decidido utilizar KMeans con k=4, es decir, generando 4 grupos con el uso de los datos escalados con diferentes técnicas conjuntas. Se ha considerado descartar el resto de técnicas debido a la falta de coherencia en los grupos que se han ido generando (falta de separación, falta de grupos compactos, escasa relación entre variables).

A continuación se va a proceder al análisis de este tipo de agrupamiento con el objetivo de exponer las razones por las cuales lo hemos elegido. Para ello vamos a comenzar comentando que el coeficiente de silhouette el cual nos da 0.21 lo cual es mayor que 0, lo que puede decir que hay una separación notable, pero no del todo definida.

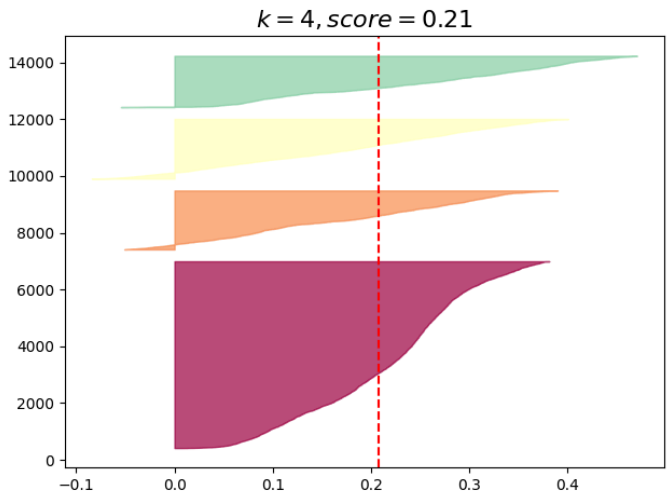

Como podemos apreciar en esta gráfica los clusters llegan a 0.4, sin embargo hay puntos sobre todo en los 3 primeros clusters de la gráfica que probablemente más que a los clusters a los que se les ha asignado por KMeans pertenecerían a otro cluster, lo cual haría que el resultado mejorase. También podemos apreciar que el cluster morado es el que más puntos tiene.

A continuación vamos a analizar el resultado de la representación con PCA, lo cual nos ha permitido como en el resto de los casos anteriores conocer si el resultado tiene sentido o no de manera visual,y nos ayuda a elegir el mejor resultado.

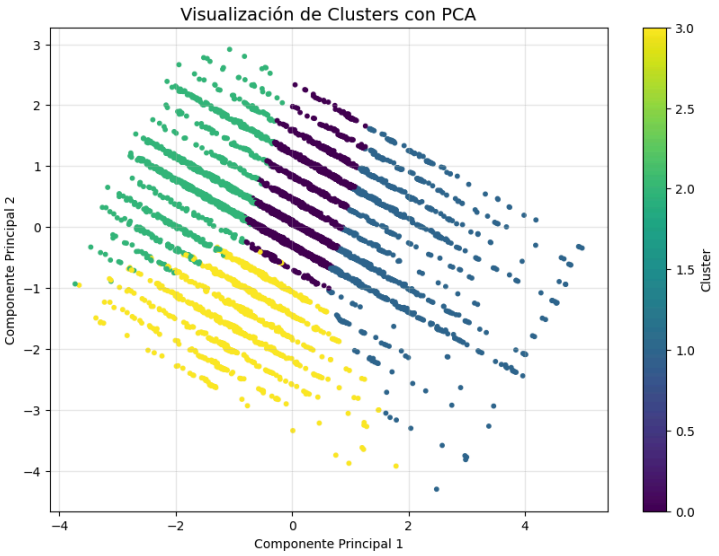

Como podemos ver en este gráfico, a diferencia de todos los anteriores este resultado sí que parece que hay una agrupación más o menos con sentidos, ya que como podemos ver apreciamos que hay zonas que están separadas de otras, lo cual es lo que buscamos. También podemos ver el hecho que hemos visto con la gráfica del silhouette hay zonas como el cluster con el morado que hay puntos que parece que no están asignado correctamente. A pesar de ello hemos decidido que este tipo de agrupamiento es el que más sentido nos aporta, además de tener buenos resultados en el silhouette.

A continuación vamos a intentar justificar que características principales agrupa cada cluster, para ello nos apoyamos en los siguientes gráficos de boxplots donde representaremos cada variable frente a los correspondientes clusters (los mejores boxplots que hemos obtenido). Vamos a comenzar con la variable edad.

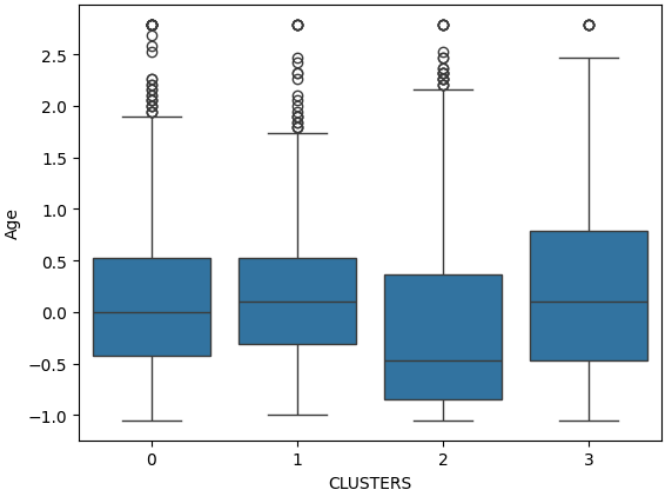

Como podemos ver en este gráfico, la edad parece ser aquello que está influyendo en KMeans haciendo que haya puntos que no se asignen correctamente, ya que como podemos ver que las edades son bastante parecidas para todos los clusters. Sin embargo podemos apreciar, que el cluster 2 tiene ligeramente una edad inferior al resto, mientras que el cluster 3 tiene una edad ligeramente superior al resto.

A continuación analizaremos el nivel de educación frente a los clusters de tal forma que podamos apreciar al igual en la edad que los clusters representan qué nivel de educación se ha recibido. Para ello nos ayudaremos del siguiente cluster:

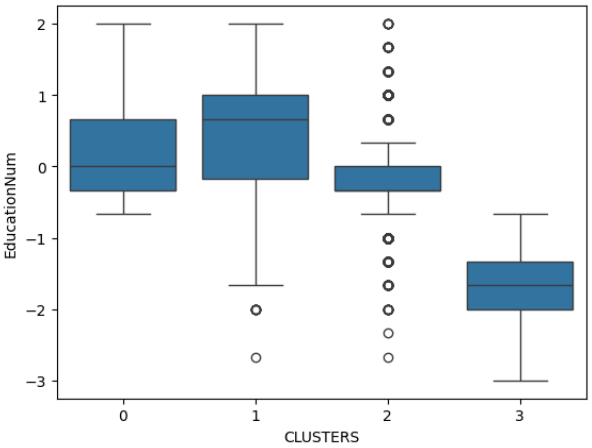

Para esta variable sí que podemos apreciar que hay diferencias entre el nivel de educación de cada cluster, podemos apreciar que el cluster 3 tiene un nivel de educación claramente más bajo que el resto. También podemos ver que el nivel de educación en el cluster 1 es el más alto mientras que en el cluster 2 y 0 tienen niveles de educación medios.

Finalmente vamos a analizar la cantidad de horas trabajadas en la semana, con el objetivo de al igual que en los dos casos anteriores conocer qué clusters corresponden con determinadas cantidad de horas. Para ello nos apoyaremos en el siguiente gráfico

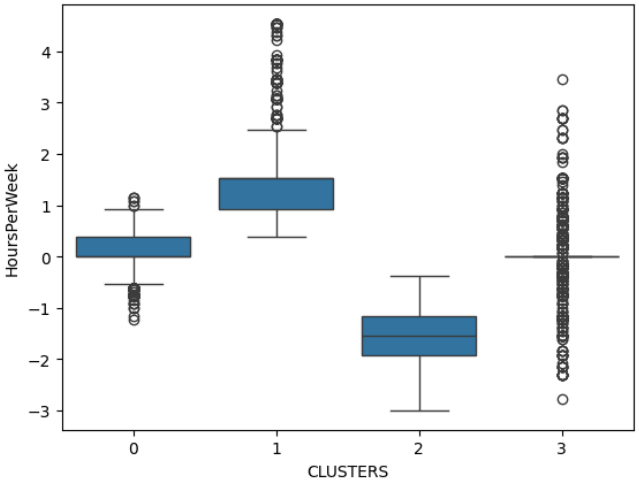

Como podemos apreciar, de igual manera que en el caso anterior, existen diferencias entre los clusters. Podemos apreciar que el cluster 2 son aquellos que menos horas trabajan a la semana, mientras que el cluster 1 es aquel que más horas trabaja

En definitiva el resultado que hemos obtenido con esta agrupación puede ser analizado como lo siguiente:

- Cluster 2: Personas más jóvenes y que menos horas trabajan, esto puede ser por personas que sean estudiantes, por lo que trabajan menos que aquellos que han acabado los estudios. Pueden ser estudiantes de universidad ya que tienen unos estudios de nivel medio como puede ser el grado
- Cluster 3: Personas con una educación más baja que el resto, pero con una edad mayor que el resto, esto se puede corresponder en personas mayores ya que hace años el nivel de educación de las personas era mucho menor que en la actualidad.
- Cluster 1: Personas con un nivel de educación elevado como puede ser el doctorado o el máster, siendo las personas que más trabajan. Se puede corresponder con directivos de empresas o profesores de universidad ya que mezclan la investigación con la docencia.
- Cluster 0: Son aquellas personas que con un nivel de educación medio, trabajan un tiempo que no es ni muy bajo ni muy alto. Parece ser aquel cluster en el que KMeans no consigue asignarlos a ningún cluster, por lo que crea uno con esos individuos, pudiendo representar a aquellos que trabajan una cantidad media de horas con unos estudios medios (muchos trabajadores así en la actualidad).

4.Conclusión

A lo largo del proyecto hemos comprobado la importancia y la necesidad del preprocesamiento y del tipo de escalado aplicado antes de realizar cualquier tipo de clustering con el fin de lograr un resultado óptimo.

El análisis inicial nos permitió conocer más a fondo lo datos, identificando variables redundantes como Education y EducationNum, comprobando la existencia de datos nulos o redundantes, así como observar patrones claros, como por ejemplo la mayor presencia de hombres o la falta de valores distintos en CapitalGain, que pueden ser de gran ayuda en el análisis final del trabajo.

Tras probar distintos métodos de escalado (KMeans, Jerárquico, DBScan y Mixturas de Gauss), llegamos a la conclusión de que a lo mejor es necesario la utilización de diferentes herramientas de

escalado para poder encontrar grupos de manera más correcta, debido a la inexistencia de un método que garantice el modelo perfecto. Del mismo modo, otro factor influyente es el objetivo del proyecto y el agrupamiento, es decir, no se obtendrá los mismos resultados si se desea obtener grupos basándonos en el capital ganado que el obtenido si deseamos que ese factor no influya.

El método elegido como opción favorable ha sido KMeans con cuatro grupos, ya que tras valorar todos los resultados obtenidos, esta técnica se ajusta tanto a nuestras preferencias como a las gráficas que deseábamos obtener, aquellas que tuviesen alto valor significativo con grupos claramente diferenciados entre ellos.

Sin embargo, como se ha comentado, creemos que una sola técnica de clustering no es suficiente para obtener agrupamientos perfectos que estén separados entre sí y sean compactos. Una mejora futura de este proyecto, sería la búsqueda de un conjunto de técnicas que no hayamos visto en clase que se ajusten a los datos usados que nos permitiese lograr los objetivos propuestos

En definitiva, el proyecto no solos nos ha permitido ver que parámetros o aspectos hay que tener en cuenta sino que nos ha permitido tener un mayor contacto con las situaciones y demandas del mundo real y de los procedimientos que tendremos que llevar a cabo en nuestro día a día y que nos ofrecen grandes herramientas para poder realizar un buen análisis de variables.

5. Referencias

No se ha utilizado referencia externa